

ANALYSE EXPLORATOIRE DES DONNEES (EDA) & PREPARATION DES DONNEES

Detection de Fraude Mobile Money (DataTour 2026)

Dossier de candidature & rapport technique exhaustif
presente a l'equipe OpenAI dans le cadre de la Bourse ML 2026.

Auteur : Equipe Octave (Octave Bahoun)

Date : Juin 2026

Lieu : Cotonou, Benin / Paris, France

1. Introduction et Definition du Probleme

Le Mobile Money (transfert et paiement d'argent via reseau telephonique mobile) connaît une croissance explosive en Afrique subsaharienne. Il s'agit d'une alternative directe aux comptes bancaires traditionnels, offrant une flexibilité et une accessibilité incomparables pour des millions d'utilisateurs. Cependant, cette absence d'infrastructures lourdes de controle bancaire fait du Mobile Money une cible de choix pour les reseaux cybercriminels et les fraudeurs.

Comment s'organise la fraude dans la realite ?

La fraude dans les systemes Mobile Money ne releve pas seulement d'attaques techniques complexes. Dans la grande majorite des cas, elle prend la forme d'escroqueries sociales :

- **Le Social Engineering (Ingenierie Sociale)** : Des cybercriminels contactent des utilisateurs en se faisant passer pour des agents du service client ou des operateurs telephoniques. Ils les incitent a effectuer des codes de transaction specifiques (ex. envoi d'argent ou cash-out) ou a leur divulguer leur code secret (PIN).
- **L'Account Takeover (Usurpation de Compte)** : Le piratage de comptes legitimes pour vider instantanement les fonds accumules.
- **Les Comptes Mules (Mule Accounts)** : L'utilisation de faux comptes ou de comptes crees sous de fausses identites pour recevoir l'argent vole et le retirer rapidement (cash-out) aux bornes physiques avant toute intervention ou blocage.

Objectif de notre developpement

Dans le cadre de la competition DataTour 2026 (Phase Nationale), notre objectif est d'analyser l'historique de transactions afin de concevoir un systeme capable de detecter en temps reel la probabilite qu'une nouvelle transaction soit frauduleuse. Pour chaque transaction du jeu de test (test.csv), nous devons predire un score continu compris entre 0.0 (legitime) et 1.0 (fraude). Ce score sert ensuite a calculer la metrique officielle de la competition : le ROC-AUC.

2. Structure du Dataset et Analyse de la Variable Cible

L'ensemble du travail de preparation et de feature engineering repose sur un historique complet de transactions. Le fichier train.csv contient 1 290 081 transactions decrites par 11 colonnes. Le fichier test.csv contient 430 100 transactions chronologiquement posterieures.

Qualite de la donnee brute :

- Valeurs manquantes : 0 (aucune valeur nulle a imputer sur les variables d'origine)
- Lignes dupliquees : 0 (aucun doublon n'a ete detecte)
- Types de donnees : homogene et correct (identifiants textuels, soldes et montants en float64)


Analyse de la variable cible (fraud_flag)

La variable a predire est le 'fraud_flag', une variable binaire ou 1 designe une fraude et 0 une transaction legitime. Sur l'ensemble du train, on compte :

- Transactions legitimes : 1 160 539 (89.96%)
- Transactions frauduleuses : 129 542 (10.04%)
- Soit un ratio d'environ 1 transaction frauduleuse pour 9 legitimes.

Important : Le desequilibre de classe (Imbalanced Classes)

Avec un taux de fraude de 10%, la metrique classique 'Accuracy' (exactitude) est trompeuse. Un modele naif qui predit 0 pour toutes les transactions obtiendrait 89.96% de bonnes reponses, tout en etant absolument inutile. C'est pourquoi la competition impose le ROC-AUC comme metrique d'evaluation principale.



3. Type d'Operation - L'Insight Fundamental

Le systeme Mobile Money anonymise les transactions sous cents codes d'operation : op_01, op_02, op_03, op_04 et op_05. L'analyse croisee entre le type d'operation et le taux de fraude revele un resultat spectaculaire.


Statistiques de fraude par type d'operation

L'analyse montre que la fraude n'est pas repartie uniformement sur les differentes operations. En realite, elle se concentre a 100% sur un seul type d'operation :

- op_01 : 4 087 transactions | 0 fraude (Taux de fraude : 0.00%)
- op_02 : 71 876 transactions | 0 fraude (Taux de fraude : 0.00%)
- op_03 : 415 323 transactions | 129 542 fraudes (Taux de fraude : 31.19%)
- op_04 : 305 443 transactions | 0 fraude (Taux de fraude : 0.00%)
- op_05 : 493 352 transactions | 0 fraude (Taux de fraude : 0.00%)

Insight majeur pour la modelisation :

Toutes les fraudes (100.0%) du dataset d'entrainement appartiennent exclusivement au type 'op_03'. Les quatre autres operations ne presentent aucun risque historique de fraude. Cette regle constitue un signal determinant. Nous integrons cette decouverte dans nos features via la variable 'operation_fraud_rate' qui prend la valeur 0.3119 pour op_03 et 0.0000 pour les autres.



4. Analyse Temporelle et Strategie de Validation

Les donnees sont associees a une variable temporelle anonymisee nommee 'period'. L'analyse montre que :

- Le jeu d'entrainement couvre les periodes 0 a 105 (soit 106 periodes distinctes).
- Le jeu de test couvre les periodes 106 a 143 (soit 38 periodes dans le futur).

Pourquoi un split de validation classique echouera ? (Data Leakage)

Dans la majorite des projets de Machine Learning, on se contente d'un fractionnement aleatoire (ex. train_test_split de scikit-learn). Ici, c'est une erreur critique. Si nous separons nos donnees de maniere aleatoire, notre modele apprendra en utilisant des transactions du futur pour predire le passe. Cela cree du data leakage (fuite d'information) et donne un score artificiellement eleve en validation, suivi d'un effondrement sur le vrai jeu de test.


Strategie de validation mise en place :

Nous appliquons un split temporel strict. Les donnees d'entrainement (train) sont divisees en :

- Train Set : Periodes 0 a 76 (80.3% des donnees du train original, taux de fraude : 9.10%)
- Validation Set : Periodes 77 a 105 (19.7% des donnees, taux de fraude : 13.86%)

Variation temporelle du taux de fraude

Le taux de fraude fluctue considerablement selon les periodes (entre 4.08% et 18.37%). Cette variation suggere que la fraude survient par vagues d'attaques coordonnees dans le temps, ce qui confirme la pertinence d'une validation temporelle pour valider la robustesse du modele face a ces fluctuations.



5. Analyse Quantitative des Montants (Amount)

Le montant d'une transaction est un indicateur de risque central. L'analyse des distributions met en evidence plusieurs regles claires qui separent les transactions frauduleuses des transactions legitimes.

Seuils de montant et dispersion


L'etude comparee des montants montre que :

- Montant minimum d'une fraude : 19 815.43
- Montant minimum d'une transaction legitime : 0.37
- Ecart-type (dispersion) des fraudes : 20 999 (tres faible)
- Ecart-type des transactions legitimes : 110 417 (tres large)

Observations :

Les fraudes n'existent pas sur les petits montants (seuil strict a 19 815.43). Les fraudeurs recherchent des montants importants pour maximiser leur gain. De plus, la dispersion des fraudes est tres faible : les montants frauduleux se regroupent dans une fenetre specifique (entre 19 815 et ~560 000), tandis que les transactions legitimes s'etendent de 0 a plus de 2.5 millions.

Afin de stabiliser la distribution et d'attenuer l'impact des outliers pour les modeles comme la regression logistique, nous avons applique une transformation logarithmique : $\log_amount = \log(amount + 1)$.



6. Comptabilite des Balances et Comportement des Comptes

Le systeme Mobile Money enregistre pour chaque transaction les soldes de l'envoyeur et du receveur avant et apres l'operation. Cela permet de realiser des verifications comptables fondamentales.

Verification de la coherence comptable

Theoriquement, le solde final doit correspondre au solde initial moins le montant (pour l'envoyeur) ou plus le montant (pour le receveur). Nous mesurons l'erreur absolue pour detecter des anomalies :

- $\text{origin_balance_error} = |\text{balance_before} - \text{amount} - \text{balance_after}|$
- $\text{dest_balance_error} = |\text{balance_before} + \text{amount} - \text{balance_after}|$

Les donnees de l'EDA montrent que les anomalies comptables sont presentes dans les deux classes de transactions. Cela s'explique par le fait que les frais de transaction sont directement preleves sur les soldes sans apparaitre dans le montant brut. Neanmoins, ces incoherences sont exploitees par le modele en conjonction avec d'autres features.

Comportement des comptes d'origine

Le dataset comporte 13 431 comptes d'origine uniques. En moyenne, un compte initie 96 transactions. Certains comptes n'ont aucune fraude historique, tandis que d'autres sont impliquees dans plusieurs fraudes. Nous creons des variables comportementales agregrees (ex. acc_o_fraud_rate , acc_o_mean_amount) sur le train uniquement pour eviter les fuites de donnees.




7. Correlations et Feature Engineering

Afin d'aider le modele de Machine Learning a capturer les signaux de fraude, nous avons developpe 29 nouvelles features (variables derivees). Notre dataset final compte ainsi 35 variables.


Matrice de correlation (Spearman)

La correlation de Spearman est utilisee pour mesurer la relation monotone entre les variables, ce qui est plus robuste aux outliers que la correlation de Pearson.



Feature Importance et validation

Le graphique d'importance montre quelles variables possèdent la correlation la plus forte avec notre cible (fraud_flag). Les soldes finaux, les ratios de montants par rapport au solde initial, et les agrégats de comptes d'origine font partie des indicateurs les plus puissants.



8. Choix et Justification des Modeles de Machine Learning

Pour aborder la modelisation, nous recommandons une strategie progressive basee sur des modeles robustes, capables de traiter le fort volume de donnees (1.3M lignes) et de maximiser le score ROC-AUC.

1. Baseline : Regression Logistique (ROC-AUC attendu : 0.75 - 0.82)

La Regression Logistique servira de modele de reference. Rapide et entierement interpretable, elle permet de valider la qualite du feature engineering. Elle necessite une standardisation prealable des variables et l'utilisation du parametre `class_weight='balanced'` pour compenser le desequilibre de classe.

2. Modele Principal : LightGBM (ROC-AUC attendu : 0.90 - 0.97)

LightGBM (developpe par Microsoft) est notre recommandation principale. Sur un jeu de donnees de plus d'un million de lignes, sa vitesse d'entrainement est 5 a 10 fois superieure a celle de XGBoost, tout en maintenant une precision equivalente ou superieure. Il gere le desequilibre nativement via `'is_unbalance=True'` et permet d'eviter l'overfitting via un controle strict de la profondeur (`num_leaves`).

3. Modele Secondaire : XGBoost (ROC-AUC attendu : 0.90 - 0.97)

XGBoost est le deuxieme modele recommande. Tres robuste et repute dans les competitions de donnees tabulaires, il offre d'excellentes performances. Nous l'utiliserons avec `scale_pos_weight=9` pour compenser le desequilibre de classe.

4. Strategie d'Ensemble

La meilleure performance finale sera obtenue par un assemblage (Ensemble) de nos modeles. Une simple moyenne ponderee des probabilites predites par LightGBM (40%), XGBoost (40%) et un Random Forest (20%) permettra de stabiliser et d'ameliorer significativement le ROC-AUC final.

9. Conclusion et Organisation du Travail

Ce travail exhaustif d'analyse exploratoire et de preparation des donnees etablit une base solide, exempte de data leakage et enrichie de variables metier discriminantes. Les donnees preparees sont pretes a etre injectees dans les modeles de Machine Learning.

Fichiers de donnees prepares (dans le dossier local)

- **train_prepared.csv** : 1 035 820 lignes d'entrainement enrichies des 29 features.
- **val_prepared.csv** : 254 261 lignes de validation (split temporel strict).
- **test_prepared.csv** : 430 100 lignes de test pretes pour la prediction finale.

Organisation des livrables (dossier 'EDA by Octave')

Conformement aux specifications, toutes les pieces de ce projet ont ete copiees et structurees dans le dossier de livraison nomme 'EDA by Octave'. Vous y trouverez :

- Le notebook Google Colab interactif (notebook_colab.ipynb)
- Le script Python local autonome (eda_local.py)
- Le document de conseil et choix des modeles (choix_modeles.md)
- La documentation Markdown complete (EDA_DOCUMENTATION.md)
- Le dossier eda_outputs contenant tous les graphiques exportes au format PNG
- Ce rapport technique final au format PDF (Livable_EDA_Octave.pdf)

Equipe Octave - DataTour 2026

Pret pour soumission a la Bourse ML d'OpenAI